Proyecto 2 — *Checkpoint*

Derivaciones 1.1, 1.2 y 4.3, simulación 1.3 y estimados 2.1

Análisis y Ciencia de Datos, Universidad del Istmo

Supuestos del BG/NBD

(i) Mientras está activo, el cliente i compra según un proceso de Poisson con tasa λ_i; (ii) $\lambda \sim \text{Gamma}(r, \alpha)$; (iii) después de cada compra (repetida) muere con probabilidad p_i; (iv) $p \sim \text{Beta}(a, b)$; (v) $\lambda_i \perp p_i$. Datos por cliente: x compras repetidas en $(0, T]$, la última en t_x.

1.1 Verosimilitud de un cliente

Fijemos λ y p, y sean $t_1 < \cdots < t_x$ los momentos de las compras repetidas. Hay dos historias que producen los mismos datos.

A: sigue vivo en T. Los tiempos entre compras son exponenciales, así que la densidad de las x compras es $\lambda e^{-\lambda t_1}\lambda e^{-\lambda(t_2-t_1)}\cdots\lambda e^{-\lambda(t_x-t_{x-1})} = \lambda^x e^{-\lambda t_x}$. Sobrevivió a las x compras, $(1-p)^x$, y estando vivo no compró en $(t_x, T]$, $e^{-\lambda(T-t_x)}$:

$$L_A = (1-p)^x \lambda^x e^{-\lambda T}.$$

B: murió justo después de la x-ésima compra. Misma densidad de compras $\lambda^x e^{-\lambda t_x}$; sobrevivió a $x-1$ compras y murió tras la última, $p(1-p)^{x-1}$; ya muerto, no comprar en $(t_x, T]$ tiene probabilidad 1:

$$L_B = p(1-p)^{x-1}\lambda^x e^{-\lambda t_x}.$$

Como son excluyentes,

$$L(\lambda, p \mid x, t_x, T) = (1-p)^x \lambda^x e^{-\lambda T} + \delta_{x>0}\, p(1-p)^{x-1}\lambda^x e^{-\lambda t_x}.$$

La historia B no existe si $x = 0$: en el BG/NBD solo se puede morir justo después de una compra *repetida*; sin recompras no hubo oportunidad de morir, y el cliente está vivo en T por construcción. Solo aparecen (x, t_x, T): son estadísticos suficientes.

1.2 La mezcla

Con $g(\lambda) = \alpha^r \lambda^{r-1} e^{-\alpha\lambda}/\Gamma(r)$ y $f(p) = p^{a-1}(1-p)^{b-1}/B(a,b)$, y por (v), cada término se factoriza. Para $s \in \{T, t_x\}$:

$$\int_0^\infty \lambda^x e^{-\lambda s} g(\lambda)\, d\lambda = \frac{\alpha^r}{\Gamma(r)} \int_0^\infty \lambda^{r+x-1} e^{-(\alpha+s)\lambda} d\lambda = \frac{\Gamma(r+x)\alpha^r}{\Gamma(r)} \frac{1}{(\alpha+s)^{r+x}},$$

$$\int_0^1 (1-p)^x f(p)\, dp = \frac{B(a, b+x)}{B(a,b)}, \qquad \int_0^1 p(1-p)^{x-1} f(p)\, dp = \frac{B(a+1, b+x-1)}{B(a,b)}.$$

Por lo tanto

$$L(r,\alpha,a,b \mid x,t_x,T) = \frac{\Gamma(r+x)\alpha^r}{\Gamma(r)}\left[\frac{B(a,b+x)}{B(a,b)}\frac{1}{(\alpha+T)^{r+x}} + \delta_{x>0}\frac{B(a+1,b+x-1)}{B(a,b)}\frac{1}{(\alpha+t_x)^{r+x}}\right].$$

Para $x=0$, $L=(\alpha/(\alpha+T))^r$ no depende de (a,b): los clientes sin recompras no informan sobre la muerte. Verificamos numéricamente la fórmula contra la integral de 1.1 por Monte Carlo (4×10^6 sorteos): errores relativos $< 4\times10^{-4}$.

1.3 Simulación

$(r,\alpha,a,b)=(0.25,4,0.8,2.5)$, 2,357 clientes, $T\sim U(27,39)$, 50 semillas. Cada cliente compra con tiempos exponenciales de tasa λ_i y tras cada recompra muere con probabilidad p_i. Estimación por máxima verosimilitud sobre log-parámetros (L-BFGS-B con cotas $[-10,10]$ desde 6 arranques, pulido con Nelder–Mead).

	verdadero	media	desv. est.	sesgo %	CV %
r	0.25	0.254	0.010	1.4	4.0
α	4.0	4.048	0.274	1.2	6.9
a	0.8	0.859	0.195	7.4	24.4
b	2.5	2.747	0.727	9.9	29.1
$a/(a+b)$	0.242	0.241	0.018	−0.8	7.4

Se recuperan los parámetros (cobertura de ±1.96 d.e. entre 92 % y 96 %). r y α se estiman mucho mejor que a y b: el 57 % de los clientes simulados tiene $x=0$ y no aporta información sobre (a,b), y la muerte solo se infiere del silencio $T-t_x$ de los recompradores. Además $\widehat{a}$ y $\widehat{b}$ están muy correlacionados (0.93): la media $a/(a+b)$ está bien identificada, la dispersión de la beta no.

2.1 Estimados en CDNOW

	r	α	a	b	log-verosimilitud
Nuestro	0.2426	4.4136	0.7929	2.4259	−9582.43
Artículo	0.243	4.414	0.793	2.426	−9582.4

4.3 La probabilidad de comprar

$Z=0$ si el cliente está muerto en T, o si está vivo y no compra en $(T,T+\tau]$. (1) Como solo se muere justo después de comprar, un vivo que no compra sigue vivo; cero compras es el evento Poisson con probabilidad $e^{-\lambda\tau}$. (2) La parte de λ de la historia "vivo" es $\lambda^x e^{-\lambda T}$, así que $\lambda \mid \text{vivo} \sim \text{Gamma}(r+x,\alpha+T)$. (3) Mezclando,

$$\mathbb{P}(0 \text{ compras en } \tau \mid \text{vivo}) = \left(\frac{\alpha+T}{\alpha+T+\tau}\right)^{r+x} \implies \mathbb{P}(Z=1 \mid x,t_x,T) = \mathbb{P}(\text{vivo} \mid x,t_x,T)\left[1-\left(\frac{\alpha+T}{\alpha+T+\tau}\right)^{r+x}\right].$$

El mismo argumento vale para el MBG/NBD, que solo cambia $\mathbb{P}(\text{vivo})$.