Contando clientes con modelos Buy 'Til You Die

BG/NBD desde cero: derivación, estimación, pronóstico y sus límites

Análisis y Ciencia de Datos

29 de octubre de 2026

Facultad de Ingeniería, Universidad del Istmo de Guatemala

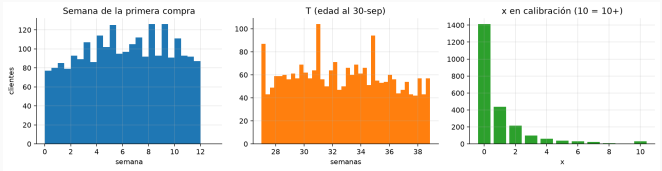
La pregunta

- Contexto no contractual: una tienda no ve cuándo se va un cliente.
- El gerente quiere saber: ¿cuántas compras harán mis clientes? ¿quiénes siguen "vivos"?
- Los BTYD responden con solo tres números por cliente: x (frecuencia), t_x (recencia) y T (edad).
- BTYD es una *familia*: proceso de compra + proceso de muerte + heterogeneidad (+ gasto). El BG/NBD es una elección.

Modelo	Compra	Muerte
Pareto/NBD	Poisson, $\lambda \sim$ Gamma	cualquier momento
BG/NBD	Poisson, $\lambda \sim$ Gamma	justo después de cada recompra, $p \sim$ Beta
MBG/NBD	Poisson, $\lambda \sim$ Gamma	también tras la primera compra

Datos: CDNOW (Fader, Hardie y Lee, 2005)

- 2,357 clientes, primera compra en Q1-1997; 6,919 registros $\rightarrow$ 6,696 transacciones cliente-día.
- Calibración: 39 semanas (al 30-sep-1997). *Holdout*: 39 semanas.
- 59.9 % no recompra en calibración.
- $T \in [27, 38.9]$: la cohorte se adquirió escalonadamente, pero la calibración termina igual para todos.



Parte 1: el modelo, pieza por pieza

1.1 Un cliente: dos historias

Con λ, p conocidos, la densidad de x compras Poisson es $\lambda^x e^{-\lambda t_x}$.

- **Vivo en T:** sobrevivió x compras y no compró en $(t_x, T]$: $(1-p)^x \lambda^x e^{-\lambda T}$.
- **Murió tras la x-ésima:** $p(1-p)^{x-1} \lambda^x e^{-\lambda t_x}$.

$$L(\lambda, p \mid x, t_x, T) = (1-p)^x \lambda^x e^{-\lambda T} + \delta_{x>0}\, p(1-p)^{x-1} \lambda^x e^{-\lambda t_x}$$

Si $x = 0$ no hay historia B: solo se muere justo después de una compra *repetida*. Un cliente sin recompras está vivo por construcción.

1.2 La mezcla

Integrando $\lambda \sim \text{Gamma}(r, \alpha)$ (mezcla gamma–Poisson) y $p \sim \text{Beta}(a, b)$ (definición de B):

$$L = \frac{\Gamma(r+x)\alpha^r}{\Gamma(r)} \left[\frac{B(a, b+x)}{B(a,b)} \frac{1}{(\alpha+T)^{r+x}} + \delta_{x>0} \frac{B(a+1, b+x-1)}{B(a,b)} \frac{1}{(\alpha+t_x)^{r+x}} \right]$$

- Programada en logaritmos con `gammaln`, `betaln`, `logaddexp`; segundo término solo para $x > 0$.
- Optimizamos log-parámetros: L-BFGS-B con cotas ± 10 desde 6 arranques + Nelder–Mead.
- Chequeo: Monte Carlo de la integral de 1.1 coincide con la fórmula (error $< 0.04\,\%$).
- Para $x = 0$: $L = (\alpha/(\alpha+T))^r$ no depende de a, b.

1.3 ¿Recuperamos parámetros que nosotros pusimos?

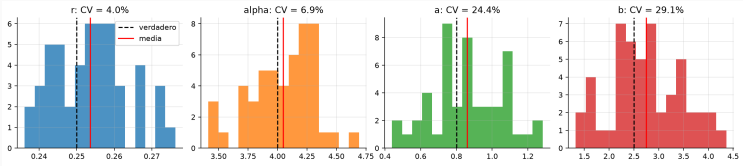
$(0.25, 4, 0.8, 2.5)$, 2,357 clientes, $T \sim U(27, 39)$, **50 semillas**.

	media	d.e.	CV
r	0.254	0.010	4 %
α	4.05	0.27	7 %
a	0.86	0.20	24 %
b	2.75	0.73	29 %
$a/(a+b)$	0.241	0.018	7 %

Sí: sesgo $<$ 0.5 d.e., cobertura 92–96 %.

¿Por qué a, b son imprecisos?

- 57 % con $x = 0$: cero información sobre la muerte.
- La muerte se infiere del silencio $T - t_x$, que también puede ser λ baja.
- $\text{corr}(\hat{a}, \hat{b}) = 0.93$: la *media* de p está bien identificada, su dispersión no.



Parte 2: ajuste a CDNOW

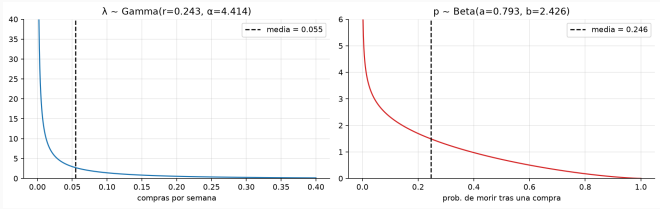
2.1 Estimados: idénticos al artículo

	r	α	a	b	LL
Nuestro	0.2426	4.4136	0.7929	2.4259	-9582.43
Artículo	0.243	4.414	0.793	2.426	-9582.4
Bootstrap EE	0.014	0.45	0.18	0.71	

- Un arranque se perdió en $a \to 0$, $b \to \infty$ con LL $= -9763$: optimizador perdido, por eso varios arranques.
- Bono 2.3: bootstrap (300 réplicas) $\approx$ hessiano $\approx$ simulación para a, b; para α el bootstrap es mayor (0.45 vs 0.38): señal de algo de mala especificación en el proceso de compra.

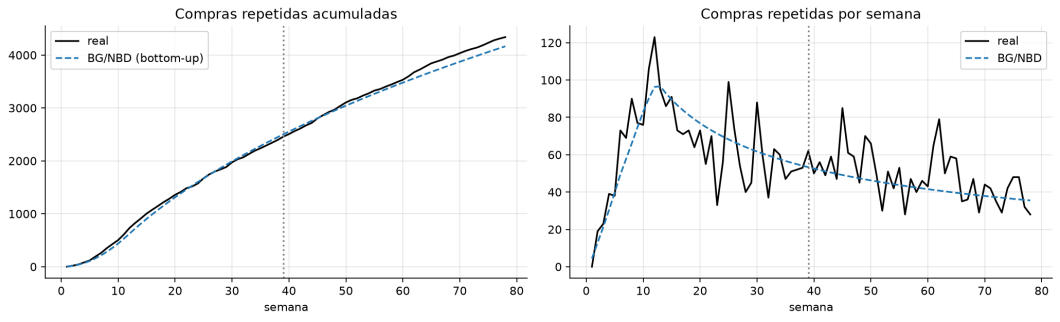
2.2 Clientes muy distintos entre sí

- $E[\lambda] = r/\alpha = 0.055/\text{sem}$ ($\approx$2.9 recompras/año), pero mediana 0.009: forma de L, CV $= 2$.
- $E[p] = a/(a+b) = 0.246$: uno de cada 4 se va tras cada recompra ($\approx$4 recompras de vida).
- $a < 1$: muchos muy leales y una cola de "desertores".



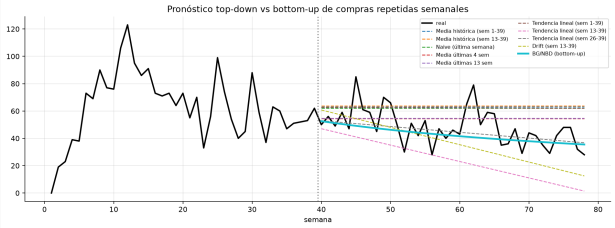
Parte 3: bottom-up vs top-down

3.1 Bottom-up: $\sum_i E[X(t - s_i)]$



Semana 78: 4,166 pronosticadas vs 4,339 reales $\Rightarrow$ $-4.0\,\%$, igual que el artículo. Solo *holdout*: 1,664 vs 1,882 ($-11.6\,\%$).

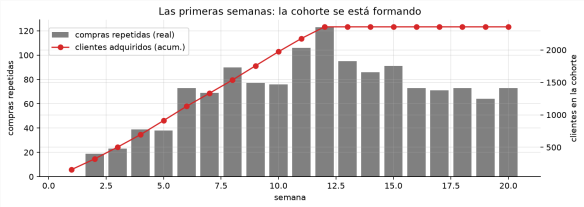
3.2–3.3 Top-down: ¿cuál ventana?



Método	error	MAE
Tendencia (26–39)	−7 %	9.3
BG/NBD	−12 %	9.8
Media últ. 4	+13 %	12.3
Media últ. 13	+13 %	12.4
Drift (13–39)	−24 %	15.1
Naive	+28 %	16.6
Tendencia (1–39)	+29 %	16.7
Media (1–39)	+31 %	17.3
Tendencia (13–39)	−50 %	24.2

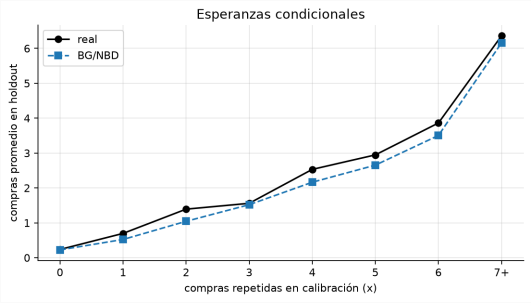
El ganador ex post depende de la ventana: la misma tendencia va de −50 % a +29 %. El BG/NBD no tiene ventanas que escoger.

3.3 Las primeras 12 semanas



- La cohorte se está formando: llegan clientes hasta la semana 12, y las recompras suben por pura adquisición.
- Desde la 13 la cohorte está cerrada y se va muriendo.
- Un top-down solo ve "sube y baja"; no sabe que la adquisición paró ni cuántos siguen vivos.

3.4 Por cliente: esperanzas condicionales



- $x = 0$: 0.225 vs 0.237 real (artículo: 0.23 vs 0.24). $x = 3$: 1.52 vs 1.56.
- Más error en $x = 1, 2$ ($-25\,\%$): el modelo mata demasiado pronto a los que recompraron poco.
- $\text{corr}(x^*, E[Y]) = 0.626$, como en el artículo.
- Un top-down no puede hacer esto: no sabe quién compone el total.

Parte 4: ¿quién sigue vivo?

4.1–4.2 $\mathbb{P}(\text{vivo})$ como clasificador: peor que una moneda

Tasa base: 29.0 % compra en el *holdout*.

	pred 0	pred 1
$Z = 0$	254	1419
$Z = 1$	139	545

Exactitud 34 % (vs 71 % de "nadie compra").
AUC $= 0.316$.

¿Por qué?

- Con $x = 0$, $\mathbb{P}(\text{vivo}) = 1$ exactamente: sin recompras no hubo oportunidad de morir.
- Pero de esos 1,411 solo compra el 13.7 % (vs 51.9 % con $x > 0$).
- El ranking pone primero, empatados, al grupo que menos compra.
- Entre $x > 0$, AUC $= 0.70$.

"Vivo" no es "va a comprar".

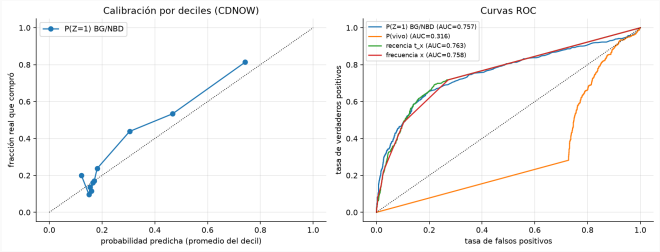
4.3 La probabilidad correcta

1. En el BG/NBD solo se muere tras comprar $\Rightarrow$ un vivo que no compra sigue vivo: $P(0 \text{ en } \tau \mid \lambda) = e^{-\lambda\tau}$.
2. Posterior: $\lambda \mid \text{vivo} \propto \lambda^{r-1}e^{-\alpha\lambda} \cdot \lambda^{x}e^{-\lambda T} \Rightarrow \text{Gamma}(r+x, \alpha+T)$.
3. Gamma–Poisson: $P(0 \text{ en } \tau \mid \text{vivo}) = \left(\frac{\alpha+T}{\alpha+T+\tau}\right)^{r+x}$.

$$\boxed{\mathbb{P}(Z=1 \mid x, t_x, T) = \mathbb{P}(\text{vivo}) \left[1 - \left(\frac{\alpha+T}{\alpha+T+\tau}\right)^{r+x}\right]}$$

4.4: verificada por simulación (20 copias de la cohorte): en cada decil fórmula y simulación difieren < 0.013.

4.5 En datos reales: ¿ordena mejor que una sola variable?

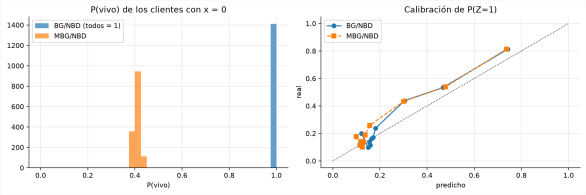


	AUC
$P(Z=1)$	0.757
recencia t_x	0.763
frecuencia x	0.758

Brier 0.161 vs 0.206 (tasa base).

Honestamente: no ordena mejor que la recencia. Lo que aporta: probabilidades calibradas, cualquier horizonte, totales y $E[Y]$, sin etiquetas.

4.6 MBG/NBD: cambiar una pieza



	BG	MBG
LL	−9582.43	−9582.14
$\mathbb{P}$(vivo), $x = 0$	1.00	0.41
AUC $\mathbb{P}$(vivo)	0.316	0.687
AUC $P(Z = 1)$	0.757	0.760
Brier	0.1612	0.1614
Holdout (real 1882)	1664	1572

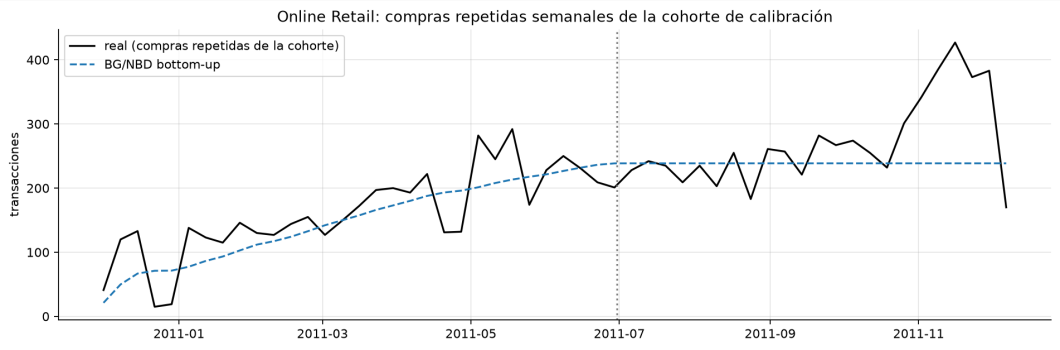
La fórmula de 4.3 sigue valiendo (muerte solo tras comprar). Para la promoción: ordenan igual (Spearman 0.98); MBG si se reporta $\mathbb{P}$(vivo), BG para niveles.

Parte 5: Online Retail

5.1 Nadie se muere

- 2,957 clientes; calibración dic-2010 a jun-2011, *holdout* 23 semanas.
- $\hat{r} = 0.74$, $\hat{\alpha} = 9.17$, pero $\hat{a} \to 0$, $\hat{b} \to \infty$: $E[p] \approx 10^{-11}$. Mismo LL que el NBD sin muerte (-15107.235).
- ¿Por qué? **Mayoristas** que reabastecen; **silencios cortos** ($T - t_x$ medio 6 vs 16 semanas; solo 8 % con más de medio año callado vs 69 % en CDNOW); **calibración corta** y "primeras compras" que no lo son (30 % aparece en dic-2010: truncamiento por la izquierda, sobrevivientes).

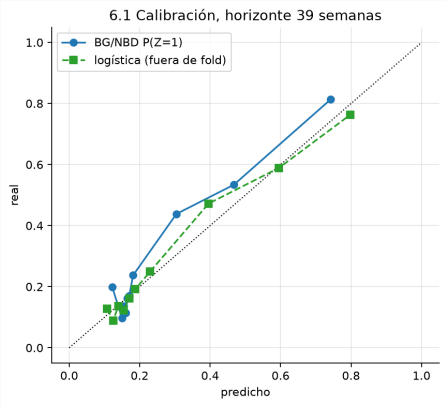
5.2 No ve venir noviembre



Holdout: 5,489 vs 6,313 reales (−13 %). Jul–ago +7–10 %; noviembre −38 %. El BG/NBD supone tasas constantes: sin estacionalidad no puede anticipar la temporada navideña de los mayoristas, lo mismo que vimos en la tarea de series.

Parte 6: ¿le gana una logística?

6.1–6.2 La comparación ingenua (y por qué no es justa)



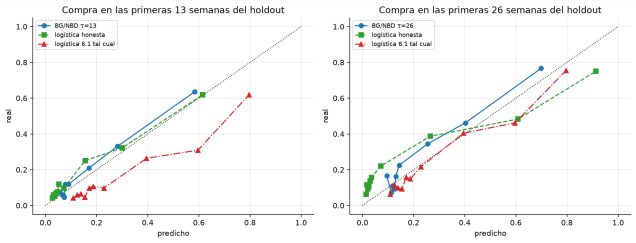
CV 5 *folds* × 20 semillas:

	AUC	Brier
Logística	0.779	0.156
BG/NBD	0.757	0.161

Coeficientes: t_x $+0.80$, x $+0.47$, T -0.23.

Fuga: aprendió con etiquetas del *holdout* de esta misma cohorte. El 30-sep-1997 esas etiquetas no existían; igual que la validación cruzada aleatoria en series de tiempo.

6.3–6.4 La versión honesta y cambiar de horizonte



13 sem (real 17.1 %)	AUC	Brier
Logística honesta	0.792	0.112
BG/NBD $\tau = 13$	0.785	0.110
Logística 6.1	0.791	0.128
26 sem (real 25.1 %)		
Logística honesta	0.785	0.156
BG/NBD $\tau = 26$	0.762	0.148

La logística honesta extrapola: se entrena con $T \in [14, 26]$ y se aplica a $T \in [27, 39]$. La de 6.1 usada a 13 semanas promedia 29 % cuando la tasa es 17 %.

6.5 Veredicto

Logística

- Pregunta fija, mismo horizonte, sobre todo *ordenar*.
- Hay etiquetas de un periodo anterior comparable.
- Se quieren más variables (monto, canal...).

BG/NBD

- Se necesitan *niveles*: cuántos compran, cuántas compras, CLV.
- Horizonte variable sin reentrenar.
- Total de la base *bottom-up*.
- No hay etiquetas del pasado (cohorte nueva).

Lo mejor de los dos: usar $P(Z = 1)$ y $E[Y(\tau)]$ del BG/NBD como variables de la logística.

Conclusiones

1. Verosimilitud a mano validada: recupera parámetros simulados y reproduce el artículo (estimados, $-4\,\%$ acumulado, condicionales, $\rho = 0.626$).
2. Bottom-up le gana a casi todo top-down sin escoger ventanas: sabe que la cohorte está cerrada.
3. "Vivo" $\neq$ "va a comprar": $\mathbb{P}(\text{vivo}) = 1$ para $x = 0$ es un artefacto del supuesto de muerte; $P(Z = 1)$ es la pregunta correcta.
4. El BG/NBD es una elección: en Online Retail la muerte desaparece y la falta de estacionalidad cuesta $38\,\%$ en noviembre.
5. La logística solo "gana" si ve el futuro.

Código: notebook `proyecto2.ipynb` + paquete `btyd/` (todo a mano con `scipy`).